



윤경은

AI Engineer (Agent)

yge0307@gmail.com

github.com/ykgstar37-lab

yge-portfolio.vercel.app

존재하지 않는 조항을 확신 있게 인용하는 응답을 경험하며, LLM 출력은 신뢰 대상이 아니라 검증 대상이라고 판단했습니다.

저는 모델 성능이 아닌 시스템 구조로 정확도를 개선합니다. 측정 없이 개선하지 않습니다.

LLM 호출을 줄이는 구조로 비용 85% 절감 — 의도 분류 기반 3-node 파이프라인 설계.

Guardrail 설계로 환각·과신 차단 — 4중 검증 + Confidence 보정. 정확도 37%→85%.

정량 지표로 병목 특정 — RAGAS로 검색·생성 분리 측정. Precision +14.4%.

3개 프로젝트(6개월) · 40 API · 2,500+ 시설 3종 의도 분기 · Flask→Django + AWS 배포.

EDUCATION

가천대학교

응용통계학과

2020.03 ~ 2026.08

SK네트웍스 Family AI Camp

SKN 21기 — LLM·RAG 실전 프로젝트

2025.09 ~ 2026.03

CERTIFICATES

SQLD (SQL 개발자)

한국데이터산업진흥원

ADsP (데이터분석 준전문가)

한국데이터산업진흥원

SKILLS

AGENT / LLM (MAIN)

LangGraph

LangChain

ChromaDB

Qdrant

vLLM

LoRA

RAGAS

SSE Streaming

OpenAI API

BACKEND / INFRA

FastAPI

Django

PostgreSQL

SQLite

Docker

Nginx

AWS (EC2, S3, RDS)

DATA / ML

Python

pandas

scikit-learn

React 19

Tailwind CSS

Recharts

PROJECTS

Seoul Culture Map — LLM 호출을 줄이는 구조로 비용 85% 절감

Personal · 2026.03 ~

github.com/ykgstar37-lab/seoul-culture-map · LangGraph · ChromaDB · FastAPI · SSE

학술제 군집분석 결과가 PDF로만 남아 아무도 쓸 수 없었던 경험에서 출발. 모든 요청에 LLM을 호출할 필요가 없다는 판단으로, 의도 분류 기반 3-node 파이프라인을 설계.

Problem: "안녕"과 "강남구 박물관 추천"이 같은 파이프라인을 탐. 비용과 품질 모두 제어 불가.

Solution: LangGraph 3-node. Intent 분류로 일상대화는 검색 스킵. SQL+ChromaDB 병렬 검색(LLM 비용 \$0). SSE 스트리밍 + 세션 메모리(10턴).

Result: 비용 **85% 절감**(~\$0.003/req) · 임베딩 \$0(로컬) · 첫 토큰 ~500ms · 15 API.

조건분기는 복잡도를 높이는 것이 아니라 낮추는 설계라고 확인했다. 이 경험이 이후 Workflow Agent의 멀티 에이전트 라우팅 설계로 이어졌다.

LangGraph ChromaDB FastAPI SSE SQLite React 19 Leaflet scikit-learn

GPT-4o-mini

Workflow Agent — Guardrail 설계로 환각·과신 차단, 정확도

Team(4명) · 2026.02 ~ 04

37%→85%

github.com/SKNETWORKS-FAMILY-AICAMP/SKN21-FINAL-3TEAM · vLLM · LoRA · Qdrant · FastAPI

sLLM이 confidence 0.95를 출력하면서 틀린 답을 내는 상황을 반복적으로 마주하며, 모델 성능 개선보다 시스템 레벨 검증이 더 효과적이라고 결론 내렸다.

Problem: "인턴에게 AWS 접근 권한을 줘도 되나요?" → "yes"(오답) + confidence 0.92(과신) + "제12조"(미존재 조항). 정확도 37.2%.

Solution: 4중 Guardrail로 환각 차단. 5-factor Confidence 보정으로 과신 제한. LoRA v3에서 19건만 약점 타겟팅.

Result: 정확도 **37%→85%** · confidence 0.92→0.78 · 환각→실존 조항 2건 인용 · JSON 유효율 70%→97%.

LLM 출력은 검증 대상이지 신뢰 대상이 아니라는 결론을 내렸다. LoRA v2에서 98건 추가 시 -3.2%p 하락한 경험이 전환점이 되어, 데이터는 양이 아닌 약점 타겟팅이 품질을 결정한다는 원칙을 확립했다.

vLLM LoRA LangGraph Qdrant KoELECTRA FastAPI SSE RunPod A100

Docker

"답변이 부정확하다"는 피드백이 반복되었지만 원인을 모르는 상태였다. 감으로 모델을 바꾸기보다 RAGAS 도입을 제안하여 병목을 특정하고 구조적으로 해결했다.

Problem: 팀에서 "LLM을 바꾸자"는 의견이 나옴. 원인 모르는 상태에서 모델을 바꾸는 건 감으로 약을 바꾸는 것과 같다고 판단.

Solution: RAGAS 4개 지표로 검색·생성 분리 측정. 병목은 embedding으로 재정의. 768D→3,072D 교체 + Qdrant 재설계. Reranker 경량화(-1초). Flask→Django + AWS 배포.

Result: Precision **0.83→0.97**(+14.4%) · Recall **0.70→0.79**(+12.7%) · Reranker -1초 · 502 에러 직접 해결.

"답변이 안 좋다"는 증상이지 진단이 아니라는 결론을 내렸다. 이 경험이 이후 프로젝트에서 "측정 먼저, 개선은 그 다음"이라는 원칙으로 이어졌다.

Qdrant RAGAS text-embedding-3-large cross-encoder Reranker LangChain Django
Nginx AWS EC2

STATISTICS FOUNDATION

암호화폐 변동성 GARCH 분석 2023.12~2024.01
5개 GARCH 모형 비교 → HAR-TGARCH-X 선택 ($R^2=0.89$). ADF-ARCH-LM 사전 검정, AIC/BIC 기반 모형 선택 과정이 이후 RAG 파이프라인에서 정량 지표 기반 의사결정의 기초가 되었다.

서울 관광 군집분석 → Seoul Culture Map 서비스 확장 2023.09~11 · 학술제 2등상

25개 자치구 관광시설 K-means 군집분석(PCA 설명력 91.3%). PDF 보고서로만 남은 결과를 "누구나 탐색할 수 있는 서비스"로 만들겠다는 문제의식 → Seoul Culture Map 프로젝트로 발전.