



GENON G.ENG. - AI ENG. INTERN

윤경은

LLM Agent · RAG · 데이터셋/평가 기반 AI 솔루션 엔지니어

Introduction

지원 동기

GENON 공고를 고객사 업무·데이터를 테스트 가능한 Agent PoC로 바꾸는 역할로 읽었습니다.

GenON G.Eng 인턴 공고를 고객사별 업무·데이터를 테스트 가능한 Agent PoC로 바꾸고,
GenOS 테스트페이지에서 지표·로그로 검증하는 역할로 해석했습니다.

WorkFlow Agent의 Guardrail·데이터셋 재구성, PyMate의 RAG 병목 진단, Seoul Culture Map의 Intent Routing 경험을 바탕으로
테스트페이지 구현·고객사 커스터마이징·모델 학습 데이터셋 관리·Agent 생성 업무에 기여하겠습니다.

검증 가능한 Agent/RAG 구조를 만드는 개발자

저는 Agent를 만드는 데서 끝내지 않고, 고객 환경에서 반복 테스트하며
실패 원인을 좁히는 구조를 설계하는 데 강점이 있습니다.

LLM 응답은 검색 품질, confidence, JSON validity, 비용, 응답 지연처럼 확인 가능한 지표로 나눠 검증합니다.

7개월간 3개 AI 프로젝트에서 Python API, RAG 평가, LangGraph Agent,
LoRA 데이터셋, vLLM 서버를 다루며 "동작하는 데모"를 넘어
고객 환경에서 반복 개선할 수 있는 구조로 정리해왔습니다.

Personal Information

NAME	윤경은
EDUCATION	- 가천대학교 응용통계학과 · 경영학과 : 2020.03 ~ 2026.08 졸업 예정 - SK Networks Family AI Camp : 2025.09 ~ 2026.03
CERTIFICATIONS	- SQLD (SQL Developer) - TOEIC Speaking IM2
EMAIL	yge0307@gmail.com
GITHUB	github.com/ykgstar37-lab
PORTFOLIO	yge-portfolio.vercel.app

Core Skills

LLM / AGENT

LangGraph LangChain OpenAI API vLLM LoRA PyTorch

BACKEND / INFRA

Python FastAPI Django REST Docker AWS EC2 Nginx

PostgreSQL

RAG / VECTOR SEARCH

RAGAS Qdrant ChromaDB BM25 HyDE RRF Reranker

DATA / EVALUATION

pandas scikit-learn SQL LLM-as-a-judge Precision/Recall

Latency/Cost

Selected Impact

AGENT RELIABILITY

37% → 85%

WorkFlow Agent: 4중 Guardrail과 confidence
보정으로 규정 판단 정확도 개선

RAG QUALITY

0.83 → 0.97

PyMate: RAGAS로 검색 병목을 분리하고
embedding-hybrid retrieval 개선

AGENT COST

85% ↓

Seoul Culture Map: Intent Routing으로 요청당 LLM
비용 \$0.020→\$0.003

Project Portfolio


1. WorkFlow Agent · LLM Agent 신뢰성 검증 및 LoRA/vLLM 서버



Team 4 · 2026.02~04 · 8주

기술 스택	LangGraph, FastAPI, vLLM, LoRA, Qdrant, Docker, RunPod A100, SSE
참여 역할	Judgment Agent, Guardrail 정책, LoRA 데이터셋 재구성, provider 패턴 서버 구조
서비스 개요	사내 규정 질의에 대해 검색 근거와 판단 결과를 제공하는 업무 보조 Agent
운영 기준	고신뢰 응답이 고객 업무에 직접 영향을 줄 수 있어 정확도보다 검증 게이트를 우선 설계

ARCHITECTURE




- **문제** 존재하지 않는 규정에도 confidence **0.92**를 출력해, 단순 threshold로는 고신뢰 오답을 막기 어려웠습니다.
- **해결** 조항 존재·카테고리·근거 일관성·출력 형식의 **4종 Guardrail**과 보정 confidence를 서버 검증 게이트로 설계했습니다.
- **결과** 규정 판단 정확도 **37%→85%**, JSON 유효율 **70%→97%**, 과신 점수 **0.92→0.78**로 개선했습니다.
- **GenON 연결** 고객사 Agent 생성 시 **규정 문서 커스터마이징·데이터셋 관리·응답 검증 시나리오**를 만드는 업무와 맞습니다.

2. PyMate · RAG 품질 진단 및 임베딩/검색 파이프라인 개선

Team 4 · 2026.01~02 · 6주

기술 스택	Python, Django, Qdrant, OpenAI Embedding, RAGAS, BM25, HyDE, RRF, AWS EC2
참여 역할	RAG 평가 지표 정의, embedding 모델 선정, retrieval pipeline 개선, Django/EC2 운영
서비스 개요	Python 공식 문서와 강의 자료 기반 학습 보조 RAG 챗봇
운영 기준	학습자 질의 반복 사용을 가정해 검색 품질과 응답 지연의 균형을 우선 설계

ARCHITECTURE




- **문제** 답변 부정확 원인이 **LLM 생성인지 검색 후보 회수인지** 분리되지 않아 개선 우선순위가 불명확했습니다.
- **해결** RAGAS 4지표로 병목을 분해하고, Precision **0.83**을 근거로 3072D embedding·BM25·RRF·reranker를 적용했습니다.
- **결과** Context Precision **0.83→0.97**, Recall **0.70→0.79**로 검색 품질을 개선했습니다.
- **GenON 연결** 고객사 문서 RAG에서 **품질 진단·검색 커스터마이징·테스트페이지 지표**를 설계하는 업무와 맞습니다.

3. Seoul Culture Map · Intent Routing 기반 Agent PoC

Personal · 2026.03~Present

기술 스택	Python, FastAPI, LangGraph, OpenAI API, ChromaDB, SQLite, SSE, React
참여 역할	개인 프로젝트: 문제 정의, 데이터 처리, Agent routing, API, 화면 구현까지 전담
서비스 개요	서울시 문화시설 2,500+개 데이터를 기반으로 조건 검색·추천 질의를 처리하는 Agent
운영 기준	월 1만 요청 가정, 불필요한 LLM 호출을 줄여 고객사 PoC 비용을 낮추는 방향으로 설계

ARCHITECTURE



- **문제** 단순 대화·조건 검색·추천 질의가 모두 같은 LLM 경로를 타며 요청 비용과 응답 지연이 커졌습니다.
- **해결** Intent→Retrieve→Generate **3-node** 구조로 분리하고, SQL filter와 ChromaDB vector search를 질의 유형별로 라우팅했습니다.
- **결과** 요청당 비용 **\$0.020→\$0.003**, 월 1만 요청 기준 **~\$200→~\$30**, 첫 토큰 약 **500ms**로 개선했습니다.
- **GenON 연결** 고객사별 트랙픽·도메인에 맞춰 **Agent 경로, 테스트 시나리오, 비용 지표**를 조정하는 업무와 맞습니다.