

SKN21 Final Project · 3TEAM

WorkFlow Agent DUDE

LangGraph 기반 멀티 에이전트 업무 자동화 시스템

규정 판단 · 문서 생성/분석 · 일정 관리를 AI가 자연어로 처리합니다



목차

Contents

OVERVIEW

- 01 팀 구성
- 02 경영지원팀의 하루
- 03 GPT를 쓸 수 없는 이유
- 04 DUDE = 유일한 해법
- 05 DUDE 핵심 기능
- 06 시연 영상

ARCHITECTURE

- 07 기술 스택
- 08 시스템 아키텍처
- 09 Multi-Agent Orchestration
 - 09-1 Judgment Agent
 - 09-2 Document Agent
 - 09-3 Schedule Agent

FINE-TUNING

- 10 Base 모델 한계
- 11 데이터셋 현황
- 12 파인튜닝 성과 비교
 - 12-1 Intent & Planner
 - 12-2 문서생성 과정
 - 12-3 문서생성 성과
 - 12-4 문서요약 과정
 - 12-5 문서요약 성과
 - 12-6 판단 과정
 - 12-7 판단 성과

WRAP-UP

- 13 Trouble Shooting & 한계점
- Q & A

팀 구성 및 역할 분담


멘토: 최민수



신지용

PM

프로젝트 관리 + 의도 분류 +
오케스트레이터
+ 문서 Agent



문지영

FE / AI

React UI + SSE 실시간 채팅
+ Intent 멀티라벨 분류 +
Planner LoRA 파인튜닝



안혜빈

BE

FastAPI + DB +
Google API 연동
+ 일정 Agent



윤경은

AI

판단 Agent + RAG
+ LoRA 파인튜닝
+ 팀스페이스 기능


경영지원팀의 하루

DUDE 도입 전후 — 같은 업무, 달라진 하루

i 제조·IT 중견기업 경영지원팀 담당자의 하루를 기반으로 구성한 시나리오입니다

Before

GPT 없이 버티는 하루



반복 업무 7시간 소모

핵심 = 1시간

After — DUDE

사내 sLLM · 보안 0건 · 비용 0원



반복 업무 13분으로 단축

핵심 = 7시간+

68%

집중 시간 부족

핵심 업무에 집중할 시간이 부족

62%

정보 검색 낭비

사내 문서와 규정 검색에 과도한 시간

57%

커뮤니케이션 부담

반복적 소통 업무에 시간 소요

GPT를 쓸 수 없는 이유

업종이 달라도 막히는 이유는 같다 — 보안 서약 · 규제 리스크



제조·IT 중견기업

대기업 납품 협력사

납품사 보안 서약서

외부 AI에 사내 데이터 전송 시 **거래 중단** — 매출 직격

2025년 현황

생성형 AI 관련 데이터 보안 사고 월평균 **2.5배 급증** — 전체 데이터 보안 사고의 14%가 AI 경유 유출

Palo Alto Networks, 2025 생성 AI 현황 보고서

"GPT가 편한 건 알아요. 근데 쓰면 거래 끊겨요."



금융·보험사

개인정보 대량 처리 업종

개인정보보호법 · ISMS

고객 데이터 외부 전송 시 **과징금 + ISMS 인증 취소** 리스크

2026년 현황

한국 기업의 **74%**가 AI를 최대 데이터 보안 위협으로 지목 — 2025년 국내 침해사고 신고 사상 최고치(2,383건, 전년 대비 +26%)

Thales 2026 Data Threat Report / 과기부·KISA 2026.1

"규정 확인에 AI를 쓰고 싶은데, 고객 정보가 섞여있어요."

보안 서약이든, 규제든 — 클라우드 AI는 쓸 수 없다

온프레미스 sLLM만이 **보안·비용·품질**을 동시에 충족하는 유일한 선택지

DUDE = 유일한 해법

GPT API, Azure 전용, 일반 오픈소스 — 어디에도 답이 없었다

	클라우드 AI GPT 등 외부 API	전용 구축 엔터프라이즈 전용	Base 모델 오픈소스 그대로	DUDE Kanana + LoRA + vLLM
데이터 보안	✕ 외부 전송	! 벤더 인프라	✓ 사내 서버	✓ 사내 서버
API 비용	종량제 사용량 비례 과금	1,000만+ 월 고정비 · 중견기업 불가	없음 GPU 운영비만	없음 GPU 운영비만
규정 판단 정확도	범용 수준 사내 규정 미학습	범용 수준 도메인 특화 별도 필요	37.2% 실무 투입 불가	85.4% LoRA 파인튜닝
Google Workspace 연동	! 제한적 별도 연동 필요	✕ 별도 개발	✕ 미지원	✓ 5종 기본 제공

Kanana-1.5-8B + LoRA + vLLM

보안 · 비용 · 품질 · 도메인 특화 — 네 가지를 동시에 충족하는 유일한 선택지

DUDE 핵심 기능

의도 자동 분류 · 복합 질문 분해 · 대화 맥락 유지



규정 판단 Agent

사내규정 기반 Yes/No/조건부 판단

근거 규정 자동 검색 + 조항 인용

신뢰도 점수 + 대안 제시



문서 처리 Agent

문서 생성 · 요약 · 검색 · QA

생성 시 규정 위반 자동 검사

Action Item 추출 → 선택하여 캘린더 등록



일정 관리 Agent

자연어 → 일정 등록 · 조회

Google Workspace 5종 연동

Meet 링크 · 초대 메일 자동 발송

06

시연 영상

실제 동작하는 DUDE를 확인하세요



기술 스택



AI / ML

LangGraph

Kanana-1.5-8B + LoRA

vLLM (RunPod A100)

roberta-large (Intent)

Qdrant + BM25

BGE Reranker



Backend

FastAPI + SSE

PostgreSQL 16 (RDS)

SQLAlchemy + Alembic

JWT + Google OAuth 2.0



Frontend

React 18 (Vite)

Zustand + TanStack Query

Tailwind + shadcn/ui

FullCalendar



Infra


AWS EC2 + RDS

Docker Compose

GitHub Actions CI/CD

RunPod A100 + Qdrant Cloud

전체 시스템 아키텍처




Multi-Agent Orchestration

Intent 분류 → Task Planning → Agent 라우팅

분류 흐름



분류 예시




6가지 Intent



핵심 특징

- **5-Seed 앙상블** — 5개 모델 투표로 안정적 분류
- **복합 질문 감지** — 멀티라벨로 2개 이상 Intent 동시 감지
- **Confidence 기반 분기** — 확신 낮으면 사용자에게 확인

복합 질문 분해 (Task Planning)



Judgment Agent 상세

사내규정 기반 판단 Agent — "이거 해도 돼?"에 근거 있는 답변

인턴에게 AWS 콘솔 접근 권한을 줘도 되나요?

conditional

조건부 허용

confidence 0.78

정보시스템 제17조에 따라 인턴은 부서장 승인 후 제한된 범위에서 시스템 접근이 가능합니다.

근거 조항	조건	대안
정보시스템 제17조 접근통제 제12조	보안 교육 이수 부서장 승인	테스트 환경 한정 접근

판단 결과 4종 — 모든 판단에 근거 조항 + confidence + reasoning 포함

yes

허용 + 근거 조항

no

금지 + 사유 + 대안

conditional

조건부 + 조건 명시

no_regulation

관련 규정 없음

2가지 동작 모드

스트리밍

2단계 처리

1) sLLM → JSON 판단
2) Base Kanana → 자연어 설명 스트리밍

비스트리밍

다른 Agent와 협업

문서 Agent · 일정 Agent에서 규정 검사 호출

Judgment Agent — 4중 보조장치

sLLM은 환각을 만든다 — RAG + 4중 검증 + Confidence 보정으로 방어

4중 보조장치



환각 탐지 예시

Q: "인턴에게 AWS 콘솔 접근 권한을 줘도 되나요?"

검증 전

result: **"yes"**
confidence: **0.92**
regulations: **"제12조"**

- 3 Qdrant에서 미존재 (환각)**
- 2 매칭률 0.0 (불일치)**

보정 후

confidence: ~~0.92~~ → **0.25**
hallucination: **true**
환각 감지 → 신뢰도 대폭 하향

5-Factor Confidence 보정

$$\begin{aligned}
 \text{Score} = & \begin{array}{|c|} \hline \text{LLM raw} \\ \times 0.60 \\ \hline \end{array} + \begin{array}{|c|} \hline \text{RAG score} \\ \times 0.25 \\ \hline \end{array} + \begin{array}{|c|} \hline \text{커버리지} \\ \times 0.15 \\ \hline \end{array} \\
 & - \begin{array}{|c|} \hline \text{규정 충돌} \\ -0.1/\text{건} \\ \hline \end{array} - \begin{array}{|c|} \hline \text{키워드 불일치} \\ \text{매칭률 기반} \\ \hline \end{array} - \begin{array}{|c|} \hline \text{조항 미존재} \\ -0.05/\text{건} \\ \hline \end{array}
 \end{aligned}$$

Base: **항상 0.9+** (과신) → 보정 후: **0.25~0.85** 현실 반영

Document Agent 상세

하나의 Agent, 4가지 다른 파이프라인



Document Agent — 템플릿 & Agent 연계

커스텀 템플릿 + Placeholder 방식 + Cross-Agent 자동 협업

커스텀 템플릿 — 사용자 양식 그대로 AI가 채운다

회사 고유 양식을 업로드하면 원본 100% 보존하면서 AI가 내용 작성



원본 양식 → Placeholder 주입

회의 제목	{{title}}
참석자	{{attendees}}
결정사항	{{decisions}}

AI가 값 치환 → 완성된 문서

회의 제목	AI 챗봇 도입 킥오프
참석자	박과장, 김대리, 정인턴
결정사항	PoC 4월까지 완료

기본 템플릿 3종

각 유형별 전용 DOCX 빌더



Cross-Agent 자동 협업



Schedule Agent 상세

한 마디로 일정 등록 + Meet 생성 + 메일 발송까지

내일 오후 3시에 팀 회의 잡아줘.
Meet 링크도 만들고 참석자들에게 초대 메일 보내줘.

일정을 등록하고 관련 서비스를 처리했습니다.



Calendar
3/31 15:00~16:00
팀 회의 등록 완료



Meet
화상 회의 링크
자동 생성



Gmail
팀원 3명에게
초대 메일 발송

일정 관리

- 등록 · 조회 · 수정 · 삭제
- 자연어 날짜/시간 파싱
- 되묻기 (Clarify) 플로우

태스크 & 결재

- 파이프라인 태스크 생성
- 연차/출장/품의 결재 요청
- 우선순위 자동 계산

Google 5종

- Calendar (양방향 동기화)
- Meet · Gmail · Tasks
- Sheets (WBS 내보내기)

AI 추천

- sLLM이 현황 분석 → 결재 추천
- sLLM이 캘린더 분석 → 일정 추천
- 문서 생성 후 일정 자동 제안

Schedule Agent — 파이프라인

자연어 파싱 → 서브액션 분류 → Google API → 후속 처리



Clarify 플로우

정보가 부족하면 되묻고, 답변 받으면 자동 이어서 처리

"내일 팀 회의 잡아줘"

'팀 회의' 일정을 등록하려고 합니다.
- 몇 시에 잡을까요? (예: 오후 3시, 14:00)

"오후 2시"

내일 14:00 팀 회의 등록 완료 ✓

AI 추천 시스템

파이프라인 현황 + 캘린더 일정을 sLLM이 분석 → 다음 할 일 자동 추천

결재 추천

일정 추천

deploy

완성된 태스크 배포 승인

HIGH

파이프라인 Done 비율이 46%로 배포/릴리즈 적기

규정 확인 필요

변경관리 절차에 따라 배포 승인 여부를 결정하는 도중 명시되어 있으나, 구체적인 배포 임계도의 기준(예: 완성도 100% 또는 중간 이상) 및 세부 절차에 대한 별도 규정이 없으므로 상황에 따라 다름.

근거: 변경관리

room

회의실 예약

medium

내일 14:00 팀 미팅 예정 → 회의실 예약 필요

Pipeline 현황

+

Calendar 일정

→

sLLM 분석

→

추천 생성

Base 모델 한계

Kanana-1.5-8B (파인튜닝 전) 실제 출력 결과

✕ 판단 Agent

입력: "인턴에게 AWS 접근 권한 줘도 돼?"

오답 "yes" 출력 (정답: conditional)

존재하지 않는 "제12조" 환각 · confidence 0.92 과신
조건/대안 필드 누락

정확도	37.2%
JSON 유효율	70.4%
no_regulation 인식률	6%
confidence	항상 0.9+ (과신)

✕ 문서생성 Agent

입력에 예산 정보가 없는데:

"budget": "연간 5억 원" ← 없는 정보를 지어냄

전체 필드의 44.3%가 환각 (False Fill)

JSON 유효율	77.3%
False Fill율	44.3%

✕ 문서요약 Agent

정답: "분류: 보고서"

Base: "분류: 뉴스기사" — 존재하지 않는 카테고리

문서관리 페이지 카테고리 필터 작동 불가

분류 유효율	85%
평균 요약 길이	274자 (장황)

Base 모델만으로는 실무 품질 미달 — 환각, 낮은 정확도, 서비스 연동 문제 → LoRA 파인튜닝으로 해결

RAG 파이프라인

"엉뚱한 규정을 가져온다" → 어떻게 고쳤는가

! 문제

"연차 며칠 쓸 수 있어?"

BM25가 "연차" 매칭 실패
구어체 ≠ 규정 문어체

정답이 3번째에 묻힘

MRR 0.636
정답 평균 2.65위



→ 3단계 해결

1. 전처리 기본기

청킹 12→44 (제N조 단위) · 동의어 23종 · 구어→문어 15패턴

2. HyDE 시멘틱 강화

LLM이 가설 규정 문서를 먼저 생성 → 이걸로 Vector 검색

"연차 며칠 쓸 수 있어?" → "유급휴가 일수 기준"
→ LLM: "제15조에 따라 1년 이상 근속 시 15일의 유급휴가를 부여한다..."

3. Cross-Encoder Reranker 핵심

bge-reranker-v2-m3가 (질문, 문서) 쌍을 직접 비교
→ 정답을 항상 1순위로 끌어올림
+ 출처당 max 3건 다양성 필터



3 성과

MRR

0.636 → 0.952

+49.7%

정답 순위	2.65위 → 1.0위
RAGAS Recall	0.944
RAGAS Precision	0.889
Hit Rate	93.3%

질의



쿼리 정제



HyDE



BM25 + Vector



RRF



Reranker




다양성 필터



Top-K

데이터셋 현황

파인튜닝 학습에 사용된 전체 데이터 현황



전체 데이터 현황

구분	출처
Intent 분류	자체 제작 + Adversarial 463
Planner	자체 제작 + GPT 증강
판단 LoRA	수동 제작(Excel) + 규정DB
문서요약 LoRA	AI Hub 요약 582건 + GPT 증강
문서생성 LoRA	AI Hub + 합성(회의록/보고서/제안서)

Track 1: 수동 제작 (고품질)

규정 판단 1,000쌍 / QA 1,000쌍 / Intent 1,453개 / Adversarial 463개

Track 2: AI Hub + 합성 (대량)

AI Hub 요약 582건 (요약) / GPT-4o 빈 필드 증강 / 합성 회의록+보고서+제안서

sLLM 파인튜닝 성과 비교

Kanana-1.5-8B + LoRA · 4개 Agent Base → LoRA 개선 결과

	Intent & Planner	문서생성	문서요약	규정 판단
	roberta + QLoRA	v3_generate	v3_summary	v1_judgment
역할	Intent 분류 + 태스크 플래닝	회의록/보고서/제안서 자동 생성	문서 분류 + 태그 + 요약	사내규정 기반 판단
Base 문제	규칙기반 41.7%	핵심 필드 채움률 34% 환각 44.3%	잘못된 카테고리 15%	오답 + 환각 근거 정확도 37.2%
학습 데이터	3,954건	1,500건	1,000건	2,949건
Base → LoRA	41.7% → 91.0% Intent 정확도	44.3% → 17.9% 환각(False Fill)	85% → 100% 분류 유효율	37.2% → 85.4% 판단 정확도

※ 모든 학습은 RunPod (A100 / H200) · Base: Kanana-1.5-8B-Instruct · 각 태스크별 과정과 성과는 다음 슬라이드에서 상세히

Intent & Planner

Intent 41.7% → 91.0% (+49.3%p) · Planner 71.0% → 87.0% (+16%p)

Intent 분류

목적: 모든 메시지의 첫 관문

채팅 입력 → 6종 분류 → Agent 라우팅
(판단/문서생성/문서검색/일정등록/일정조회/일반)

왜 LLM이 아닌 별도 모델?

- 매 메시지마다 실행 → LLM 호출 시 **1~2초 지연 + GPU 비용**
- 규칙기반 매칭은 **41.7%** — 유사 표현 구분 불가
- **경량 분류 모델**이 필요 (빠르고 정확하게)

해결: roberta-large 5-Seed 앙상블

- KoELECTRA 과적합(Dev 90% vs Held-out 77%) → roberta 교체
- Focal Loss + FGM + Knowledge Distillation
- ONNX INT8 양자화 → **추론 19ms** (LLM 대비 100배 빠름)

성능 추이 (Held-out 100건)



Task Planner

목적: 복합 요청을 단계별로 분해

"출장비 규정 확인하고 출장 보고서 작성해줘" → [규정판단, 문서생성] 순차 실행


문제: Baseline 71.0%

복합 요청에서 intent를 잘못 분류하는 케이스 발생

해결: Hybrid 프롬프트 + 후처리 매핑

- 잘못 분류된 intent를 규칙으로 보정
- Rule Guide 9개로 경계 케이스 처리
- Kanana-1.5-8B QLoRA r=16 (Qwen3 대비 5배 빠름)

성능 추이 (Holdout 100건)



1-step
91.5%

2-step
84.9%

3-step
66.7%

문서생성 파인튜닝 과정

Kanana-1.5-8B + QLoRA · 1,500건 · v2 → v3 데이터 재설계

목적: 회의 내용만 입력하면 완성된 문서 초안 생성

사용자가 자연어로 내용을 입력하면 sLLM이:

- 회의록 / 보고서 / 제안서 3종 문서 자동 생성
- 챗봇 대화 한 번으로 **완성된 초안** 제공

Base 모델의 문제

- 핵심 필드(content, decisions) 채움률 **34%**
- 입력에 없는 정보를 지어냄 → **환각 44.3%**
- JSON 유효율 **77.3%**

학습 설정

Base Model Kanana-1.5-8B-Instruct

LoRA r / alpha 32 / 64 (QLoRA 4-bit NF4)

Epochs / LR 5ep (Best: ep2) / 1e-4 cosine

데이터 Synthetic + AI Hub = 1,500건

인프라 RunPod H200 143GB

해결: 3계층 필드 설계

Always

100%

content · summary

Priority

80%

decisions · action_items

Optional

~35%

agenda · risks · notes 등

Optional을 의도적으로 비워서 "없으면 채우지 마"를 학습 → 환각 방지

학습 데이터 예시

train 1,350건 / eval 150건

system

"기업 문서 작성 전문가입니다. [필드 명세]에 따라 JSON으로 생성하세요. 입력에 해당 정보가 없으면 빈 문자열로 두세요."

user

[문서 유형] 회의록 · [필드 명세] title, date, attendees, content, decisions, action_items
[회의 내용] "AI 챗봇 도입 키포프. 3월 15일 회의실B. 박과장, 김대리, 정인턴 참석. PoC 4월까지 완료 결정."

assistant (정답)

```
{"title": "AI 챗봇 도입 키포프 회의", "date": "2026-03-15",  
  "attendees": ["박과장", "김대리", "정인턴"],  
  "content": "AI 챗봇 PoC 범위와 일정을 논의하고 4월 완료 목표를 수립...",  
  "decisions": ["PoC 4월까지 완료"],  
  "action_items": [{"담당": "김대리", "내용": "벤더 3곳 비교표 작성"}]}
```


문서생성 파인튜닝 성과

v3_generate · 동일 입력, Base vs LoRA 출력 비교

사용자 입력

"AI 챗봇 도입 키포프 회의록 작성해줘. 3월 15일 회의실B. 참석자: 박과장, 김대리, 정인턴. AI 챗봇 PoC 4월까지 완료하기로 결정. 김대리가 벤더 3곳 비교표 다음주까지 작성."

BEFORE — Base 모델

회의록

생성일: 2026-03-15

제목	회의록	제네릭
날짜	2026-03-15	
참석자	박과장, 김대리	1명 누락
내용	AI 챗봇 도입에 대해 논의함	너무 짧음
결정사항	—	비어있음
예산	2,400만원	환각

AFTER — LoRA v3

AI 챗봇 도입 키포프 회의

2026-03-15 · 회의실B · 유형: 회의록

제목	AI 챗봇 도입 키포프 회의	구체적
날짜	2026-03-15	정확
참석자	박과장, 김대리, 정인턴	정확
내용	AI 챗봇 PoC 범위와 일정을 논의하고 4월까지 완료 목표를 수립하였다...	
결정사항	PoC 4월까지 완료	정확
Action Item	김대리 — 벤더 3곳 비교표 (다음주까지)	

정량 평가 (eval 150건)

평가 지표	Base	LoRA v3	변화
ROUGE-L (내용 유사도)	0.465	0.665	+43%
BERTScore F1 (의미적 품질)	0.896	0.926	+3.4%
False Fill (환각률)	44.3%	17.9%	-59%
JSON 유효율	77.3%	87.3%	+10%p
평균 출력 길이	1,593 토큰	1,395 토큰	-12.4%

문서요약 파인튜닝 과정

Kanana-1.5-8B + QLoRA · 1,000건 · 문서관리 페이지 자동 분류 + 키워드 + 요약

목적: 문서관리 페이지 자동화

사용자가 문서를 업로드하면 sLLM이 자동으로:

- **분류** (7종 카테고리 필터)
- **키워드 추출** (태그 기반 검색)
- **요약** (목록 미리보기 텍스트)
- **챗봇 연동** (DB 저장된 요약 즉시 반환)

Base 모델의 문제

요약 자체는 가능하지만:

- **"뉴스기사"** 등 없는 카테고리 15% → **분류 필터 작동 불가**
- 평균 **274자** 장황 + 포맷 불일치 → 서비스 품질 미달

학습 설정

Base Model	Kanana-1.5-8B-Instruct
LoRA r / alpha	16 / 32 (QLoRA 4-bit NF4)
Epochs / LR	5ep (Best: ep2) / 1e-4 cosine
데이터	AI Hub 300 + GPT 합성 700
인프라	RunPod H200 143GB

해결: 포맷 통일

- 출력 **분류:/태그:/요약:** 3줄 통일
- 분류 **7종 명시** · 1,000건 전부 이 포맷으로 학습

분류: 보고서

카테고리 필터

태그: #경주시 #황리단길 #관광객 #코로나19

키워드 검색

요약: 경주시 황리단길은 코로나19 이후 관광객의 방문이 점차 회복되고 있다.

미리보기

학습 데이터 예시

train 900건 / eval 100건

system

"문서 분류 및 요약 전문가입니다. 분류, 태그, 요약을 생성하세요. 분류: 회의록/보고서/제안서/계약서/정책문서/인사 문서/기타"

user

"경주시 황리단길은 코로나19로 인한 관광 침체에서 벗어나 젊은 관광객들로 붐비고 있다. 2023년 3~5월 기준, 주요 관광지 방문객 수는 전년 대비 20~40% 증가했으며..."

assistant (정답)

분류: 보고서

태그: #경주시 #황리단길 #관광객 #코로나19

요약: 경주시 황리단길은 코로나19 이후 관광객의 방문이 점차 회복되고 있다.

문서요약 파인튜닝 성과

v3_summary · 문서 업로드 → 자동 분류 + 태그 + 요약이 서비스에 반영

BEFORE — Base (274자)

분류: **뉴스기사** 7종에 없음

태그: 경주관광, 코로나영향, 방문객회복... **심표 구분**

요약: 코로나19로 인해 침체되었던 경주 관광지의 방문객 수가 점차 회복세를 보이고 있습니다. 3~5월 기준 방문객 수는 지난해 대비 20~40%까지 증가... **(장황)**

AFTER — LoRA v3 (132자)

분류: **보고서** 유효 카테고리

태그: #경주시 #황리단길 #관광객 #코로나19 **#접두사 통일**

요약: 경주시 황리단길은 코로나19 이후 관광객의 방문이 점차 회복되고 있다. **(핵심)**

LoRA 출력이 문서관리 페이지에 반영되는 모습

전체 **보고서** 회의록 제안서 +4

보고서 경주 관광 현황 보고서

#경주시 #황리단길 #관광객 #코로나19

경주시 황리단길은 코로나19 이후 관광객의 방문이 점차 회복되고 있다.

↑ 분류 → 필터 ↑ 태그 → 검색 ↑ 요약 → 미리보기

정량 평가 (eval 100건)

지표	Base	LoRA	변화
분류 유효율	85%	100%	+15%p
BERTScore F1	0.828	0.859	+0.031
평균 길이	274자	132자	2배 간결
ROUGE-L	0.20	0.31	+0.11

판단 Agent 파인튜닝 과정

v1_judgment · 사내규정 기반 yes/no/conditional 판단 · "LLM을 맹신하지 않는" 구조

목적: 사내 규정 기반 자동 판단

"이거 해도 돼?" 질문에 sLLM이 규정을 근거로:

- **yes / no / conditional** 판단
- 근거 조항 + 조건 + 대안 제시
- **confidence**로 신뢰도 표시

Base 모델의 문제

- 정확도 **37.2%** — 절반 이상 오답
- 존재하지 않는 "제12조" 인용 → **환각**
- confidence 항상 **0.9+** — 틀려도 과신
- no_regulation 인식을 **6%**

학습 설정

Base Model	Kanana-1.5-8B-Instruct
LoRA r / alpha	16 / 32 (bf16)
Epochs / LR	3ep / 2e-4 cosine
데이터	수동 제작(Excel) + 증강 = 2,949건
인프라	RunPod A100 80GB

해결: 3단계 실험 여정

"RAG를 학습에 넣으면 좋을까?" → 실험으로 답을 찾다



v2에서 RAG 노이즈로 **-9.8%p 급락** → "학습은 하드코딩(깨끗한 신호), 서빙만 RAG(실시간 검색)" 전략 확정

학습 데이터 예시

train 2,949건 / eval 328건

system

"기업 내부 규정 판단 전문가입니다. 규정 문서를 기반으로 판단하세요. 결과는 JSON으로: result(yes/no/conditional/no_regulation), confidence, reasoning, regulations, conditions, alternatives"

user

관련 규정 문서
정보보안규정 - 제25조 (시스템 접근 권한)
"외부인 및 인턴은 부서장 승인 후 제한된 범위에서..."

질문
"인턴에게 AWS 콘솔 접근 권한을 줘도 되나요?"

assistant (정답)

```
{"result": "conditional",  
 "conce": 0.82,  
 "reasoning": "정보보안규정 제25조에 따라...",  
 "regulations": [{"article": "제25조"}],  
 "conditions": "부서장 승인 + 보안교육 이수",  
 "alternatives": ["테스트 환경 한정 접근"]}
```


판단 Agent 파인튜닝 성과

v1_judgment · 동일 질문, Base vs LoRA 출력 비교

사용자 질문 + RAG 컨텍스트: 정보보안규정 제5장, 인사규정 제8조

"인턴에게 AWS 콘솔 접근 권한을 줘도 되나요?"

BEFORE — Base (37.2%)

판단 "yes" 오답 (정답: conditional)

confidence 0.92 근거 없이 과신

근거 조항 "제12조" 환각 (존재하지 않음)

조건/대안 — 누락

AFTER — LoRA v1 (85.4%)

판단 "conditional" 정답

confidence 0.78 불확실성 반영

근거 조항 정보시스템 제17조, 접근통제 제12조 실존

조건 보안 교육 이수 + 부서장 승인

대안 테스트 환경 한정 접근

카테고리별 정확도 (eval 328건)

카테고리	Base	LoRA v1	변화	포인트
no_regulation	6%	97%	+91%p	"규정에 없는 질문"을 구분
yes	42%	86%	+44%p	허용 판단 + 근거 조항
no	48%	84%	+36%p	금지 판단 + 이유 명시
conditional	47%	78%	+31%p	조건부 — 경계 모호 (한계)
전체 정확도	37.2%	85.4%	+48.2%p	JSON 유효율 70.4% → 97.6%

Trouble Shooting & 한계점

개발 중 해결한 문제 · 아직 남은 과제

해결한 핵심 이슈 — 5건 전부 해결

#	문제	원인	해결
1	Intent 과적합 (Dev 90% vs Held-out 77%)	112M 모델이 패턴 암기	roberta-large(338M) 교체 · gap -3.3%p
2	Planner intent 혼동 (15건)	8B 사전지식을 LoRA로 못 덮음	잘못 분류된 intent 규칙 보정 · PM +13.7%p
3	vLLM 한글 깨짐	LORA_DTYPE=bfloat16 강제 변환	LORA_DTYPE=auto 로 변경
4	RAG 학습 시 성능 급락 (-9.8%p)	RAG 검색 노이즈 → 라벨 모순	학습은 하드코딩, 서빙은 RAG 정제 삽입
5	Confidence 과신 (0.95→실제 틀림)	LLM raw 점수가 근거 품질 미반영	5-factor 보정 + 4중 보조장치

남은 한계점

- Conditional 정확도 78%**
목표 85% 대비 -7%p · 조건부 판단 경계가 모호
- 3-step 복합 요청 66.7%**
1-step 91.3% 대비 낮음 · 8B 멀티스텝 추론 한계
- ROUGE-L ↑ vs False Fill ↑ 트레이드오프**
v4 실험: 채움률 올리면 환각도 증가 → v3 유지
- 커스텀 템플릿 — 복잡한 표 양식 한계**
Placeholder 방식으로 모든 양식 대응 어려움 · 특히 복잡한 표 구조

향후 발전 방향

- Conditional 데이터 정밀 보강**
레이블 재정의 + 경계 사례 추가 → 목표 85%
- 문서생성 학습 데이터 다양화**
다양한 문서 양식 기반 학습 → 더 많은 양식 지원 + 표 구조 개선
- 학습 데이터 확장 + 더 큰 모델**
8B + 현재 데이터가 천장 → 데이터 추가 또는 모델 스케일업
- Reranker 경량화 & 캐싱**
빈출 규정 캐싱 + 모델 경량화로 응답 속도 개선

WORKFLOW AGENT — DUDE

Q & A

감사합니다

SKN21 Final Project · 3TEAM

